

面向捆绑推荐的扩散驱动图优化框架

匿名稿（中文审阅版）

摘要

现有捆绑推荐方法通常利用来自用户—捆绑图、用户—物品图和捆绑—物品图的多视图信息，以准确建模用户的捆绑偏好。然而，这类多视图方法在从上述图中学习时仍面临两个关键挑战：(1) 不可靠的用户—捆绑交互可能传播误导性信号并损害偏好学习；(2) 用户—捆绑隐式反馈的稀疏性限制了可用监督信号。为此，我们提出一种面向捆绑推荐的扩散驱动图优化框架（DiGO）。首先，我们聚合每个用户交互历史中捆绑的预训练表示，并以预训练用户表示为条件，通过扩散过程建模用户的整体捆绑偏好。随后，我们利用该偏好表示对已观测的用户—捆绑交互进行评分，保留更可靠的用户—捆绑交互，并重构用户—捆绑图，以用于后续的多视图表示学习。其次，为缓解用户—捆绑隐式反馈稀疏问题，我们将从重构用户—捆绑图中学习到的表示作为锚，在融合三个视图之前，通过跨视图对比学习对齐用户—物品和捆绑—物品表示，从而利用辅助关系补充有限的用户—捆绑监督。三个公开数据集上的实验结果表明，所提框架在全部评价指标上均优于现有先进方法，相较最优基线最高取得 10% 的相对提升。

1 引言

捆绑推荐旨在从预定义的物品集合中识别符合用户兴趣的捆绑。现有方法通常联合建模用户—捆绑、用户—物品和捆绑—物品关系，并通过图神经网络、多视图融合与对比学习获得互补的用户和捆绑表示。其中，用户—物品和捆绑—物品关系提供辅助信息，而用户—捆绑图直接承载用户对捆绑的隐式反馈，其结构与监督质量会影响后续的多视图学习。尽管现有方法取得了良好进展，多视图捆绑推荐仍面临两个关键挑战。

挑战一：用户—捆绑图中的不可靠交互。用户—捆绑关系通常由隐式反馈构建，其中可能包含无法可靠反映用户偏好的交互。例如，偶然点击、尝试性选择以及由短期兴趣或曝光偏置导致的交互，可能无法稳定反映用户的实际捆绑偏好。现有图方法直接沿观测边传播信

息，使不可靠交互参与表示更新并引入误导性信号。因此，如何从用户交互历史中识别更可靠的连接并构建高质量的用户—捆绑图，仍是一个关键问题。

挑战二：用户—捆绑隐式反馈稀疏。用户—捆绑反馈远比用户—物品交互稀疏，因此只能提供有限的捆绑级监督。尽管用户—物品和捆绑—物品关系包含丰富的辅助信号，仅在最终阶段进行融合可能无法使这些信息与用户—捆绑偏好学习充分对齐。因此，如何在保持与直接捆绑偏好一致性的同时有效利用辅助视图，仍是一个重要挑战。

为解决上述挑战，我们提出 DiGO，一种面向捆绑推荐的扩散驱动图优化框架。DiGO 首先聚合每个用户交互历史捆绑的预训练表示，并以预训练用户表示为条件，通过扩散过程建模用户的整体捆绑偏好。所得偏好表示随后用于对已观测的用户—捆绑交互进行评分，保留更可靠的连接，并在不引入新边的情况下重构用户—捆绑图。最后，DiGO 以重构用户—捆绑图所学习的表示为锚，在视图融合前对齐用户—物品和捆绑—物品视图，从而补充稀疏的监督信号。DiGO 的整体框架如图 1 所示。

本文的主要贡献概括如下：

- 我们提出 DiGO，一种扩散驱动图优化框架，通过条件扩散建模用户的整体捆绑偏好，并利用该偏好重新评估已观测交互和重构用户—捆绑图。
- 我们以重构用户—捆绑图所学习的表示为锚，在视图融合前对齐两个辅助视图，从而补充稀疏的用户—捆绑监督。
- 三个公开数据集上的实验结果表明，DiGO 在全部评价指标上均优于现有方法，最高相对提升达到 10%。消融实验和进一步分析也验证了两个关键设计的有效性。

2 相关工作

捆绑推荐。 早期捆绑推荐方法主要依赖用户—捆绑交互，并采用协同过滤、矩阵分解或神经网络模型学习用




图 1: DiGO 的整体框架, 包括: (1) 用户—捆绑预训练; (2) 用于重构观测用户—捆绑图的扩散驱动图优化; (3) 以重构用户—捆绑视图为锚、在视图融合前进行跨视图对比学习的多视图捆绑推荐。

户与捆绑表示。随后, 基于图的方法进一步联合建模用户—捆绑、用户—物品和捆绑—物品关系, 以从捆绑级和物品级捕获高阶协同信息。

近期研究日益关注多视图表示学习和跨视图协同。例如, MIDGN 引入意图解耦, CrossCBR 采用跨视图对比学习, BundleGT 使用图 Transformer 建模结构信息, MultiCBR 则通过三视图融合与对比学习获得统一表示。这些方法主要改进多个视图的编码、融合或对齐方式, 但通常直接使用观测到的用户—捆绑图。与之不同, DiGO 在多视图学习之前重新评估已观测的用户—捆绑交互, 并据此重构用户—捆绑图。

推荐中的扩散模型。 扩散模型通过逐步扰动数据并学习相应的反向过程, 展现出较强的分布建模能力。近年来, 扩散模型已被应用于协同过滤、序列推荐和知识图谱推荐, 用于建模用户偏好、恢复交互信号或增强推荐表示。

扩散模型也已被引入捆绑推荐。RDifBFR 针对动态变化的捆绑—物品关系, 通过对物品级捆绑表示执行残差扩散, 使模型能够适应捆绑组成的变化。DCBR 将条件扩散应用于用户—捆绑交互数据, 并结合多视图对比学习进行推荐。与这些方法不同, DiGO 聚合每个用户交互历史中捆绑的预训练表示, 并以预训练用户表示为条件, 通过扩散过程建模用户的整体捆绑偏好。所得偏好表示随后用于评估已观测的用户—捆绑交互, 并重构后续多视图表示学习所依赖的用户—捆绑图。

3 方法

3.1 问题定义

令 $\mathcal{U} = \{u_1, u_2, \dots, u_M\}$, $\mathcal{B} = \{b_1, b_2, \dots, b_N\}$ 和 $\mathcal{I} = \{i_1, i_2, \dots, i_O\}$ 分别表示用户集合、捆绑集合和物品集合, 其中 M 、 N 和 O 分别为相应集合的大小。本文使用用户—捆绑交互矩阵 $\mathbf{X} \in \{0, 1\}^{M \times N}$ 、用户—物品交互矩阵 $\mathbf{Y} \in \{0, 1\}^{M \times O}$ 和捆绑—物品从属矩阵 $\mathbf{Z} \in \{0, 1\}^{N \times O}$ 。具体而言, $x_{ub} = 1$ 和 $y_{ui} = 1$ 分别表示用户 u 与捆绑 b 、物品 i 之间存在观测交互, 而 $z_{bi} = 1$ 表示物品 i 属于捆绑 b 。

给定 $\mathbf{X}$ 、 $\mathbf{Y}$ 和 $\mathbf{Z}$, 捆绑推荐的目标是预测每个未观测用户—捆绑对的偏好分数 $y_{u,b}^*$ 。

3.2 框架概述

如图 1 所示, DiGO 首先利用预训练表示建模每个用户的整体捆绑偏好, 并将原始用户—捆绑矩阵 $\mathbf{X}$ 重构为 $\tilde{\mathbf{X}}$ 。随后, 模型基于 $\tilde{\mathbf{X}}$ 、 $\mathbf{Y}$ 和 $\mathbf{Z}$ 从三个视图学习用户与捆绑表示。在融合三个视图之前, DiGO 以用户—捆绑视图为锚进行跨视图对齐, 并最终利用融合表示预测用户偏好。

3.3 扩散驱动图优化

偏好表示构建

我们首先在原始用户—捆绑交互上预训练 LightGCN, 以获得用户 u 和捆绑 b 的预训练表示 $\bar{\mathbf{e}}_u$ 和 $\bar{\mathbf{e}}_b$ 。

预训练模型采用 BPR 目标进行优化, 所得表示在后续图优化过程中保持固定。

令 $\mathcal{N}_u^{UB} = \{b \in \mathcal{B} \mid x_{ub} = 1\}$ 表示用户 u 历史交互过的捆绑集合。我们通过平均池化构造其历史捆绑表示:

$$\mathbf{p}_u^0 = \frac{1}{|\mathcal{N}_u^{UB}|} \sum_{b \in \mathcal{N}_u^{UB}} \bar{\mathbf{e}}_b, \quad (1)$$

其中, $\mathbf{p}_u^0$ 概括了用户交互历史中捆绑的整体特征, 并作为后续扩散过程的建模对象。

条件扩散

给定扩散步数 T 和噪声序列 $\{\beta_t\}_{t=1}^T$, 定义 $\alpha_t = 1 - \beta_t$ 且 $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s$ 。在时间步 t , $\mathbf{p}_u^0$ 的前向扰动定义为

$$\mathbf{p}_u^t = \sqrt{\bar{\alpha}_t} \mathbf{p}_u^0 + \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}). \quad (2)$$

我们以预训练用户表示 $\bar{\mathbf{e}}_u$ 作为个性化条件, 并利用条件去噪网络预测未扰动的捆绑偏好表示:

$$\hat{\mathbf{p}}_u^0 = f_\theta(\mathbf{p}_u^t, \bar{\mathbf{e}}_u, t), \quad (3)$$

其中, f_θ 为基于多层感知机的条件去噪网络, 用于融合扰动表示、用户条件和时间步嵌入。

训练过程中, 我们从 $\{1, \dots, T\}$ 中均匀采样 t , 并采样高斯噪声 $\boldsymbol{\epsilon}$ 以构造 $\mathbf{p}_u^t$ 。扩散模块采用表示重构损失和历史集合约束进行优化:

$$\begin{aligned} L_{\text{rec}}^D &= \mathbb{E}_{u \sim \mathcal{U}^+, t \sim \text{Unif}\{1, \dots, T\}, \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})} \left[\|\hat{\mathbf{p}}_u^0 - \mathbf{p}_u^0\|_2^2 \right], \\ L_{\text{set}}^D &= \mathbb{E}_{u \sim \mathcal{U}^+, t \sim \text{Unif}\{1, \dots, T\}, \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})} \left[1 - \frac{1}{|\mathcal{N}_u^{UB}|} \sum_{b \in \mathcal{N}_u^{UB}} \cos(\hat{\mathbf{p}}_u^0, \bar{\mathbf{e}}_b) \right], \\ L^D &= L_{\text{rec}}^D + \eta L_{\text{set}}^D, \end{aligned} \quad (4)$$

其中, $\mathcal{U}^+ = \{u \in \mathcal{U} \mid |\mathcal{N}_u^{UB}| > 0\}$, $\cos(\cdot, \cdot)$ 表示余弦相似度, η 用于控制历史集合约束的贡献。 L_{rec}^D 约束预测结果恢复用户历史捆绑的整体表示, 而 L_{set}^D 则鼓励预测结果与用户交互历史中的实际捆绑保持一致。

交互评分与图重构

在图重构阶段, 我们采用确定性迭代去噪过程。该过程以用户历史捆绑表示作为初始状态, 并按照时间步的逆序反复应用条件去噪网络:

$$\begin{aligned} \tilde{\mathbf{p}}_u^T &= \mathbf{p}_u^0, \\ \tilde{\mathbf{p}}_u^{t-1} &= f_\theta(\tilde{\mathbf{p}}_u^t, \bar{\mathbf{e}}_u, t), \quad t = T, T-1, \dots, 1, \\ \mathbf{p}_u^* &= \tilde{\mathbf{p}}_u^0, \end{aligned} \quad (5)$$

其中, $\mathbf{p}_u^*$ 表示最终得到的用户 u 的整体捆绑偏好表示。

随后, 我们仅对用户已观测的交互计算偏好匹配分数, 并至多保留得分最高的 κ 个捆绑:

$$\begin{aligned} s_{u,b} &= \cos(\mathbf{p}_u^*, \bar{\mathbf{e}}_b), \quad b \in \mathcal{N}_u^{UB}, \\ \tilde{\mathcal{N}}_u^{UB} &= \text{TopK}_{b \in \mathcal{N}_u^{UB}}(s_{u,b}, \kappa), \\ \tilde{x}_{ub} &= \mathbb{I}[b \in \tilde{\mathcal{N}}_u^{UB}]. \end{aligned} \quad (6)$$

其中, κ 为每个用户最多保留的交互数量, $\mathbb{I}[\cdot]$ 为指示函数。所有 $\tilde{x}_{ub}$ 构成重构用户—捆绑矩阵 $\tilde{\mathbf{X}}$ 。由于 $\tilde{\mathcal{N}}_u^{UB} \subseteq \mathcal{N}_u^{UB}$, DiGO 只重新评估和筛选已观测的用户—捆绑交互, 而不引入未观测连接。

3.4 多视图表示学习

基于 $\tilde{\mathbf{X}}$ 、 $\mathbf{Y}$ 和 $\mathbf{Z}$, DiGO 分别从用户—捆绑交互视图、用户—物品交互视图和捆绑—物品从属视图中学习表示。三个视图共享初始可训练的用户、捆绑和物品表示, 但采用彼此独立的传播路径。

令 $\text{LG}(\cdot)$ 表示包含邻域传播和层聚合的 LightGCN 编码器, 则三个视图的表示学习过程可写为

$$\begin{aligned} (\mathbf{E}_U^{UB}, \mathbf{E}_B^{UB}) &= \text{LG}(\tilde{\mathbf{X}}), \\ (\mathbf{E}_U^{UI}, \mathbf{E}_I^{UI}) &= \text{LG}(\mathbf{Y}), \\ \mathbf{e}_b^{UI} &= \frac{1}{|\mathcal{N}_b^{BI}|} \sum_{i \in \mathcal{N}_b^{BI}} \mathbf{e}_i^{UI}, \\ (\mathbf{E}_B^{BI}, \mathbf{E}_I^{BI}) &= \text{LG}(\mathbf{Z}), \\ \mathbf{e}_u^{BI} &= \frac{1}{|\mathcal{N}_u^{UI}|} \sum_{i \in \mathcal{N}_u^{UI}} \mathbf{e}_i^{BI}. \end{aligned} \quad (7)$$

其中, $\mathcal{N}_b^{BI}$ 表示捆绑 b 所包含的物品集合, $\mathcal{N}_u^{UI}$ 表示用户 u 交互过的物品集合。UB 视图直接得到用户表示 $\mathbf{e}_u^{UB}$ 和捆绑表示 $\mathbf{e}_b^{UB}$ 。在 UI 视图中, 模型根据捆绑—物品从属关系聚合物品表示, 以获得 $\mathbf{e}_b^{UI}$; 在 BI 视图中, 模型根据用户—物品交互聚合物品表示, 以获得 $\mathbf{e}_u^{BI}$ 。这种三视图组织方式遵循捆绑推荐中的标准多视图建模框架。

因此, 用户 u 获得三种视图特定表示 $\{\mathbf{e}_u^{UB}, \mathbf{e}_u^{UI}, \mathbf{e}_u^{BI}\}$, 捆绑 b 获得 $\{\mathbf{e}_b^{UB}, \mathbf{e}_b^{UI}, \mathbf{e}_b^{BI}\}$ 。

3.5 跨视图对比学习

为利用两个辅助视图补充稀疏的用户—捆绑监督, DiGO 将从重构用户—捆绑视图中学习到的表示作为锚, 在融合三个视图之前, 将其与用户—物品和捆绑—物品表示进行对齐。

对于实体集合 $\mathcal{S}$, 锚视图 a 与辅助视图 v 之间的对比损失定义为

$$\ell_\tau(\mathbf{E}^a, \mathbf{E}^v; \mathcal{S}) = -\frac{1}{|\mathcal{S}|} \sum_{x \in \mathcal{S}} \log \frac{\exp(\cos(\mathbf{e}_x^a, \mathbf{e}_x^v)/\tau)}{\sum_{x' \in \mathcal{S}} \exp(\cos(\mathbf{e}_x^a, \mathbf{e}_{x'}^v)/\tau)}. \quad (8)$$

同一实体在两个视图中的表示构成正样本对, 其余实体的表示作为批内负样本。

融合前跨视图对比损失定义为

$$L^A = \ell_{\tau_a}(\mathbf{E}_U^{UB}, \mathbf{E}_U^{UI}; \mathcal{S}_U) + \ell_{\tau_a}(\mathbf{E}_U^{UB}, \mathbf{E}_U^{BI}; \mathcal{S}_U) \\ + \ell_{\tau_a}(\mathbf{E}_B^{UB}, \mathbf{E}_B^{UI}; \mathcal{S}_B) + \ell_{\tau_a}(\mathbf{E}_B^{UB}, \mathbf{E}_B^{BI}; \mathcal{S}_B), \quad (9)$$

其中, $\mathcal{S}_U$ 和 $\mathcal{S}_B$ 分别表示当前批次中去重后的用户集合和正捆绑集合, τ_a 为温度参数。DiGO 仅在用户侧和捆绑侧构造 UB—UI 与 UB—BI 对齐, 而不额外引入 UI—BI 约束。

3.6 预测与模型优化

三个视图中的用户和捆绑表示通过视图系数进行融合, 并利用其内积预测偏好:

$$\mathbf{e}_u = \lambda_1 \mathbf{e}_u^{UB} + \lambda_2 \mathbf{e}_u^{UI} + \lambda_3 \mathbf{e}_u^{BI}, \\ \mathbf{e}_b = \lambda_1 \mathbf{e}_b^{UB} + \lambda_2 \mathbf{e}_b^{UI} + \lambda_3 \mathbf{e}_b^{BI}, \quad (10) \\ y_{u,b}^* = \mathbf{e}_u^\top \mathbf{e}_b, \quad \lambda_1 + \lambda_2 + \lambda_3 = 1.$$

DiGO 同时保留融合后的自监督对比学习。令 $\mathbf{E}'_U, \mathbf{E}''_U$ 和 $\mathbf{E}'_B, \mathbf{E}''_B$ 分别表示两次独立表示扰动产生的用户和捆绑表示, 则融合后对比损失为

$$L^C = \frac{1}{2} [\ell_{\tau_c}(\mathbf{E}'_U, \mathbf{E}''_U; \mathcal{S}_U) + \ell_{\tau_c}(\mathbf{E}'_B, \mathbf{E}''_B; \mathcal{S}_B)], \quad (11)$$

其中, τ_c 为融合后对比学习的温度参数。

对于训练三元组 (u, b, b') , 其中 $x_{ub} = 1$ 且 $x_{ub'} = 0$, 推荐损失和多视图推荐模型的整体优化目标分别定义为

$$L^{BPR} = \sum_{(u,b,b')} -\ln \sigma(y_{u,b}^* - y_{u,b'}^*), \quad (12) \\ L^R = L^{BPR} + \beta_1 L^C + \beta_2 L^A + \beta_3 \|\Theta\|_2^2,$$

其中, Θ 表示多视图推荐模型的可训练参数, β_1 、 β_2 和 β_3 分别控制融合后对比损失、融合前跨视图对比损失和正则项的贡献。

训练过程中, DiGO 首先利用 L^D 优化扩散模块并重构 $\tilde{\mathbf{X}}$, 随后以 $\tilde{\mathbf{X}}$ 、 $\mathbf{Y}$ 和 $\mathbf{Z}$ 为输入, 利用 L^R 优化多视图推荐模型。

3.7 复杂度分析

令 d 、 K 和 Q 分别表示嵌入维度、图传播层数以及每个训练轮次中的推荐小批次次数。令 C_f 表示条件去噪网络一次前向传播的计算成本。对于 DiGO 使用的固定深度多层感知机, 当其隐藏层维度和时间步嵌入维度随 d 同阶增长时, 有 $C_f = \mathcal{O}(d^2)$ 。

令 $\mathcal{E}_{UB}$ 、 $\mathcal{E}_{UI}$ 和 $\mathcal{E}_{BI}$ 分别表示原始用户—捆绑图、用户—物品图和捆绑—物品图的边集合, 并令 $\tilde{\mathcal{E}}_{UB}$ 表示重构用户—捆绑图的边集合。离线 LightGCN 预训练中的图传播开销为 $\mathcal{O}(K|\mathcal{E}_{UB}|d)$ 。在 DiGO 的每个训练轮次中, 扩散学习的复杂度为 $\mathcal{O}(|\mathcal{U}^+|C_f + |\mathcal{E}_{UB}|d)$, 其中第二项来自历史捆绑聚合和历史集合约束。

图重构还需要 $\mathcal{O}(T|\mathcal{U}^+|C_f + |\mathcal{E}_{UB}|d)$ 的复杂度, 以完成迭代去噪和已观测交互评分; Top- κ 选择至多需要 $\mathcal{O}(|\mathcal{E}_{UB}|\log \kappa)$ 。多视图推荐部分的图传播复杂度为 $\mathcal{O}(QKd(|\tilde{\mathcal{E}}_{UB}| + |\mathcal{E}_{UI}| + |\mathcal{E}_{BI}|))$, 融合前和融合后对比学习的复杂度为 $\mathcal{O}(Q(B_U^2 + B_B^2)d)$, 其中 B_U 和 B_B 分别表示一个小批次中的去重用户数和捆绑数。

由于 $|\tilde{\mathcal{E}}_{UB}| \leq |\mathcal{E}_{UB}|$, DiGO 不会因图稠密化而增加图传播开销, 同时避免了对全部 $M \times N$ 个用户—捆绑对进行评分。其参数空间复杂度为 $\mathcal{O}((M + N + O)d + P_f)$, 其中 P_f 为条件去噪网络的参数数量。